

Detecção de patologias cardíacas em pacientes pediátricos

Vinícius H. P. Cavalcanti

*Departamento de Computação (DComp)
Universidade Federal de São Carlos (UFSCar)
18052-780, Sorocaba, São Paulo, Brasil
hnrquevini@gmail.com*

Resumo—As doenças cardiovasculares são a principal causa de morte no mundo, e a cardiopatia congênita é a mais comum entre as doenças cardíacas em pacientes pediátricos. Técnicas de inteligência artificial têm sido amplamente utilizadas para auxiliar no diagnóstico de doenças cardíacas, principalmente devido à sua capacidade de processar grandes quantidades de dados e identificar padrões. Sabendo disso, este trabalho avalia o desempenho de métodos de aprendizado de máquina e redes neurais artificiais na detecção de patologias cardíacas em pacientes pediátricos. Para tal, foi utilizado um conjunto de dados com informações clínicas de pacientes pediátricos com e sem patologias cardíacas. Os resultados obtidos demonstram que modelos de aprendizado de máquina e redes neurais artificiais são capazes de identificar patologias cardíacas em pacientes pediátricos com alta precisão, especialmente quando as etapas de análise exploratória e pré-processamento dos dados são adequadamente realizados.

Keywords—doenças cardiovasculares; pediatria; inteligência artificial; classificação;

I. INTRODUÇÃO

Doenças cardiovasculares (DCV) são a principal causa de morte no mundo. A organização mundial da saúde (OMS) estima que em 2030 quase 23,6 milhões de pessoas morrerão de doenças cardiovasculares [1]. Na população pediátrica o risco de doenças cardiovasculares estão mais associados a obesidade e sedentarismo [2], mas existem outras condições que podem levar a doenças cardiovasculares, como a cardiopatia congênita, que é uma das principais causas de morte em crianças [3].

Os métodos de diagnóstico atuais para doenças cardiovasculares incluem exames de imagem como eletrocardiograma (ECG), ecocardiograma, exame radiológico do torax, ressonância magnética, tomografia computadorizada, entre outros. Além disso dispositivos tecnológicos como, relógios e anéis inteligentes estão sendo amplamente adotados para monitorar estilo de vida e fatores de risco cardiovascular [4]. Apesar da diversidade de exames disponíveis, os custos proibitivos, bem como a falta de conscientização pública sobre os fatores de risco cardiovascular e falta de exames preventivos regulares são os principais fatores que contribuem para o diagnóstico tardio de doenças cardiovasculares [5].

Dado a severidade das doenças cardiovasculares, a detecção precoce é crucial para o tratamento e prevenção de complicações. A inteligência artificial (IA) tem sido

amplamente utilizada em diversas áreas da saúde, incluindo diagnóstico de doenças cardiovasculares [6], [7], [8], [9]. A adoção da IA advém principalmente da capacidade de processar grandes volumes de dados e identificar padrões complexos que podem não ser facilmente identificados por humanos [10].

Neste contexto, esta pesquisa avalia diferentes técnicas de aprendizado de máquina e redes neurais artificiais para a detecção de doenças cardiovasculares em crianças. O objetivo é identificar a técnica mais adequada para a detecção de doenças cardiovasculares em crianças, considerando a precisão, sensibilidade e especificidade do modelo.

Esta pesquisa está estruturada da seguinte forma: a seção 2 apresenta a revisão da literatura sobre o uso de inteligência artificial para detecção de doenças cardiovasculares em crianças. As seções 3 e 4 apresentam a metodologia utilizada para a coleta de dados, pré-processamento, treinamento e avaliação dos modelos. A seção 5 apresenta os resultados obtidos, a seção 6 apresenta a estratégia final para a validação em ambiente de produção e a seção 7 apresenta as considerações finais.

II. TRABALHOS CORRELATOS

A identificação de patologias cardíacas envolve múltiplas etapas, e um histórico cardíaco detalhado é essencial nesse processo [11]. Diversos estimadores de risco foram propostos para identificar níveis de risco de doenças cardíacas, como o Framingham Risk Score [12] e o QRISK [13], no entanto, esses estimadores apresentam limitações ao não considerarem as variabilidades individuais dos pacientes [14].

A inteligência artificial tem sido amplamente utilizada para a detecção de patologias cardíacas, como em [6], onde os autores avaliaram diferentes modelos individualmente e também em conjunto, encontrando que a fusão de modelos resulta em uma performance superior em relação aos modelos individuais. Por outro lado, [7] avaliou diversos modelos de aprendizado de máquina e conseguiu atingir uma medida AUC de 87,3% com os modelos Adaptive Boosting e Random Forest. Apesar dos resultados promissores na detecção de doenças cardíacas, algumas limitações ainda persistem.

[15] levanta a questão sobre a interpretabilidade dos modelos de aprendizado de máquina, onde a complexidade desses modelos dificultam a interpretação dos resultados. A interpretabilidade é um fator crucial em aplicações médicas, pois os médicos precisam entender os motivos que levaram um modelo a tomar uma determinada decisão [16]. Além disso, há limitações relacionadas à disponibilidade de dados para o treinamento dos modelos [17]. Para superar essas limitações, diferentes abordagens têm sido propostas.

Um modelo de aprendizado por agrupamento utilizando o classificador de suporte de vetores quântico foi proposto por [8]. O modelo, além de apresentar resultados interpretáveis, conseguiu atingir uma acurácia de 90,16% na detecção de doenças cardíacas. Outra abordagem foi proposta por [9], onde os autores apresentaram um estudo de aprendizado federado com imagens de ressonância magnética cardíaca, no qual o modelo foi treinado com dados provenientes de quatro centros diferentes.

III. DADOS E PRÉ-PROCESSAMENTO

A base utilizada foi coletada originalmente no Real Hospital Português (RHP), localizado no Brasil, e faz parte de uma parceria com a Universidade do Porto, em Portugal. No total são 17.873 pacientes pediátricos, com e sem patologias cardíacas, sendo 14.727 rotulados entre as classes normal (sem patologia) e anormal (com patologia) e 3.146 não rotulados. A base possui 19 atributos contínuos e categóricos (Tabela I) que representam informações demográficas e clínicas do paciente.

Inicialmente foram tratados os valores contínuos nas observações rotuladas. Os atributos *Idade* e *FC* foram previamente convertidos de objeto para contínuo, e, em seguida foi realizada uma análise dos valores médios, desvio padrão e quartis para cada atributo.

A análise de distribuição revelou valores extremos como *Peso* negativo, *Idade* negativa, zero ou superior à faixa etária pediátrica, que, de acordo com a *Academia Americana de Pediatria*, é de 22 anos [18]. Também foram encontrados *IMC* igual a zero ou acima dos valores saudáveis, incluindo o valor máximo observado de 105,3 kg/m² para um adulto de 41 anos [19], além de *PA Sistólica* e *FC* com valores extremamente elevados, sendo acima dos limites já vistos de 360 mmHg e 480 bpm [20], [21], respectivamente.

Além dos valores extremos, foram identificados valores faltantes em praticamente todos os atributos da base. Para minimizar a inserção de viés nos dados, foram analisados 3 métodos de imputação de valores faltantes, sendo esses: imputação por mediana [22], k-vizinhos mais próximos [23] e imputação múltipla com equações encadeadas (MICE) [24], com o estimador de regressão linear bayesiana.

Para a avaliação dos métodos, foi criada uma base de dados de referência, composta pelas observações rotuladas que apresentavam até 30% de dados faltantes (*peso*, *altura*, *IMC*, *idade* e *FC*), excluindo os valores extremos e faltantes,

totalizando 9.227 observações. Em seguida, uma segunda base foi gerada a partir da base de referência, mas com a inserção aleatória de valores faltantes. Esta base foi então preenchida utilizando os métodos de imputação, sendo a base de referência usada como padrão de comparação.

Dado que os métodos de imputação são sensíveis à escala dos dados, a normalização (z-score) foi aplicada, garantindo uma média de 0 e desvio padrão de 1. Para avaliar a performance dos métodos, foram utilizadas as métricas de erro absoluto médio (MAE), erro quadrático médio (RMSE) e coeficiente de determinação (R²). O método MICE apresentou os melhores resultados, com MAE de 0.12, RMSE de 0.30 e R² de 0.90 (Tabela II), e foi, portanto, escolhido para imputação dos valores faltantes nas observações rotuladas.

Ao preencher atributos com mais de 30% de valores faltantes, foi observada uma queda nos resultados, chegando a atingir um MAE de 0.17, RMSE 0.39 e R² 0.84 para o método MICE. Como resultado, foi decidido remover os atributos *PA Sistólica* e *PA Diastólica*, que apresentavam uma quantidade de dados faltantes superior a 30%.

Após preencher os valores contínuos faltantes, foram analisados os valores categóricos, onde foi observado que o atributo *HDA 2* continha mais de 90% dos dados faltantes, e por esse motivo foi removido da base. Outros atributos com valores faltantes foram preenchidos com uma categoria própria chamada *Outros*, dessa forma, evita-se categorizar de forma errada e os modelos conseguem aprender com essas observações específicas.

A análise de categorias únicas de cada atributo revelou que alguns atributos possuíam categorias repetidas, como o atributo *Sexo*, que continha as categorias *Feminino* e *feminino*, e o atributo *Classe*, que continha as categorias *Normal* e *Normais*. Categorias repetidas foram agrupadas em uma única categoria. Atributos com categorias desbalanceadas foram agrupados em categorias semelhantes, resultando em:

- **HDA 1:** Assintomático, Sintomas Cardíacos e Sintomas Gerais
- **Pulsos:** Normais e Alterados
- **B2:** Normal e Alterado
- **Sopro:** Sistólico, Contínuo, Diastólico
- **Motivo 1:** Condição Cardíaca, Check-Up e Outro
- **PPA:** Normal, Não Calculado, Pré-hipertensão, Hipertensão e Outro

O agrupamento se deu devido a necessidade de normalizar os dados categóricos para numéricos, por conta dos modelos testados serem mais eficientes com dados numéricos.

Para a normalização dos dados foi decidido utilizar a técnica de *One-Hot Encoding* [25], que cria uma nova coluna para cada categoria, sendo assim, os modelos não assumem que as categorias são ordinais, isto é, que possuem uma hierarquia, ou que um valor é maior que o outro, por exemplo, em *Sexo*, *Feminino* ser maior que *Masculino*.

Por fim valores que não contribuem para a detecção de patologias cardíacas como *Altura*, *Atendimento*, *DN* e

Tabela I
ATRIBUTOS DA BASE DE DADOS.

Campo	Descrição
ID	Identificador único
Peso	Peso
Altura	Altura
IMC	Índice de Massa Corporal
Idade	Idade
Sexo	Gênero
Atendimento	Data do atendimento
DN	Data de nascimento
Convênio	Convênio
Pulsos	Pulso
PA Sistólica	Pressão arterial sistólica
PA Diastólica	Pressão arterial diastólica
PPA	Pressão de Pulso Arterial
B2	Segunda bulha (diastólica)
Sopro	Sopro Cardíaco
FC	Frequência cardíaca.
HDA 1 e 2	História de doença atual
Motivo 1 e 2	Motivo da consulta
Classe	Classe

Tabela II
AVALIAÇÃO DOS MÉTODOS DE IMPUTAÇÃO DE VALORES FALTANTES.

Método	MAE	RMSE	R2
Mediana	0.23	0.55	0.70
K-vizinhos	0.20	0.48	0.76
MICE	0.12	0.30	0.90

Convênio foram removidos. O resultado final foi uma base com 31 colunas (incluindo identificador único e classe) e 11.784 observações.

IV. PROTOCOLO EXPERIMENTAL

Os dados previamente pré-processados foram divididos em treino e teste, sendo 80% para treino e 20% para teste. A divisão foi realizada de forma estratificada, garantindo que a proporção de classes fosse mantida em ambos os conjuntos. A partição de teste foi mantida separada até o final do experimento, para evitar vazamento de informações. Os valores de entrada para treino foram normalizados utilizando o método *scaler* do *scikit-learn* [26], que padroniza os valores para média 0 e desvio padrão 1. A normalização foi realizada para garantir que os modelos não fossem influenciados pela escala dos dados. Para otimização dos hiperparâmetros, foi utilizada a busca em grade [27] com validação cruzada [28] de 5 partições, garantindo que os modelos fossem treinados e validados em diferentes partições dos dados e com diferentes hiperparâmetros. A busca em grade foi realizada para os modelos, k-vizinhos mais próximos (KNN) [29], naive bayes [30], regressão logística [31], máquina de suporte de vetores




Figura 1. Fluxograma do protocolo experimental

(SVM) [32] e perceptron multicamadas (MLP) [33]. Os hiperparâmetros testados para cada modelo foram:

- **K-Vizinhos mais próximos**
 - *Número de vizinhos* (3, 5, 7, 9 e 11)
 - *Pesos* (uniforme e distância)
 - *Métrica de distância* (euclidiana, manhattan e chebyshev)
- **Naive bayes**
 - *Suavizador* (1e9 até 1e-5 com passo de 1e-1)
- **Regressão logística**
 - *C* (0,1, 1, 10 e 100)
 - *Tol* (1e-4 até 1e-2 com passo de 1e-1)
- **SVM**
 - *Kernel* (rbf, poly e sigmoid)
 - *C* (0,1, 1 e 10)
- **MLP**
 - *Alpha* (0,1, 0,01 e 0,0001)
 - *Função de ativação* (relu e tanh)
 - *Solver* (adam e sgd)
 - *Tamanho da camada oculta* (100, 50, 25 e 10)

O melhor estimador encontrado pela busca em grade, para cada modelo testado, foi avaliado utilizando a partição de teste. A avaliação foi realizada utilizando as métricas de sensibilidade e especificidade, que indicam a performance dos métodos para identificar quem realmente tem/não tem patologias cardíacas, além da área de baixo da curva (AUC). O fluxograma do protocolo experimental pode ser visualizado na Figura 1.

V. RESULTADOS

Na Tabela III são apresentados os resultados obtidos para os modelos de classificação.

O modelo *Perceptron Multicamada* obteve o melhor resultado, com um AUC de 0,9490, e de modo geral, os modelos apresentaram maior especificidade do que sensibilidade, o

Tabela III
RESULTADOS DOS MODELOS DE CLASSIFICAÇÃO.

Método	Sensibilidade	Especificidade	AUC
K-vizinhos	0,9188	0,9515	0,9358
Naive Bayes	0,9202	0,9549	0,9299
Regressão Logística	0,9168	0,9591	0,9440
Máquina de Suporte de Vetores	0,9197	0,9571	0,9374
Perceptron Multicamadas	0,9179	0,9580	0,9490

Tabela IV
RESULTADOS NA CLASSIFICAÇÃO PÚBLICA DA COMPETIÇÃO.

Método	AUC
K-vizinhos	0,9385
Naive Bayes	0,9270
Regressão Logística	0,9383
Máquina de Suporte de Vetores	0,9195
Perceptron Multicamadas	0,9412

que indica que eles tiveram uma maior capacidade de identificar corretamente os casos negativos do que os positivos.

A diferença entre especificidade e sensibilidade se deu principalmente por um desbalanceamento entre as classes, entretanto, essa diferença não foi expressiva o suficiente para prejudicar a capacidade de classificação dos modelos.

Embora o modelo *Perceptron Multicamada* tenha alcançado o melhor resultado, a diferença entre os modelos foi pequena, com uma variação de no máximo 0,0191. A semelhança nos resultados pode ser explicada pelo pré-processamento aplicado à base de dados. Parte dos atributos foi gerado por meio do método *One-Hot Encoding*, que criou um novo atributo binário para cada categoria do atributo alvo, simplificando o problema e permitindo que até modelos mais simples obtivessem bons resultados.

VI. ESTRATÉGIA FINAL

Para a avaliação em ambiente de produção, os modelos foram treinados com o conjunto de dados completo, sem a divisão entre treino e teste. A predição foi feita no conjunto não rotulado (3146 observações), pré-processado utilizando os mesmos critérios da base de treino. Um arquivo CSV foi gerado com as predições, e em seguida foi submetido à competição [34]. Os resultados obtidos na competição estão na Tabela IV. Os resultados foram calculados com aproximadamente 50% dos dados de teste.

VII. CONCLUSÃO

Neste estudo foi realizada a comparação de diversos métodos de aprendizado de máquina e redes neurais artificiais para a detecção de patologias cardíacas em pacientes pediátricos. Os dados utilizados foram coletados pelo Real Hospital Português em colaboração com a Universidade

do Porto. Os dados rotulados foram devidamente pré-processados e tratados antes de serem divididos em conjuntos de treino e teste. Para a otimização dos hiperparâmetros dos modelos, utilizou-se o método de busca em grade. A avaliação dos modelos foi realizada com base nas métricas de sensibilidade, especificidade e AUC.

Os resultados obtidos demonstram que a utilização de aprendizado de máquina e redes neurais artificiais é efetiva para a detecção de patologias cardíacas em pacientes pediátricos. Além disso, a etapa de pré-processamento dos dados mostrou-se fundamental para a obtenção de bons resultados. A rede neural artificial *Perceptron Multicamadas* obteve o melhor AUC (0,9490) entre os métodos avaliados, entretanto, o desempenho dos outros modelos foi muito próximo, com uma diferença máxima de 0,0191 em relação ao pior modelo. Isso evidencia que todos os modelos avaliados são eficazes para o problema, especialmente porque os dados foram adequadamente tratados e preparados para a modelagem.

Os resultados deste estudo são promissores e sugerem que o uso de aprendizado de máquina e redes neurais artificiais pode ser uma alternativa eficaz para a detecção de patologias cardíacas em pacientes pediátricos.

Pesquisas futuras podem explorar a combinação de múltiplas fontes de dados, o que pode aumentar a generalização dos modelos em diferentes hospitais e regiões. Além disso, é fundamental a validação dos modelos em um ambiente clínico real, para avaliar sua efetividade na prática.

REFERÊNCIAS

- [1] W. H. Organization *et al.*, *Global atlas on cardiovascular disease prevention and control: published by the World Health Organization in collaboration with the World Heart Federation and the World Stroke Organization*. World Health Organization. Regional Office for Europe, 2011.
- [2] R. I. R. Dias, M. E. D. S. B. Rocha, J. N. Andrade, S. C. F. Teixeira, W. G. D. Oliveira, G. S. Fideli, C. F. D. O. Neto, S. B. C. Silva, A. C. S. Gonçalves, F. D. C. Bezerra, J. A. C. Melo, A. D. S. M. Filho, and R. M. P. Guimarães, "RISCO CARDIOVASCULAR EM CRIANÇAS E ADOLESCENTES COM OBESIDADE," *Brazilian Journal of Implantology and Health Sciences*, vol. 5, no. 5, pp. 3613–3625, Nov. 2023. [Online]. Available: <https://bjih.emnuvens.com.br/bjih/article/view/915>

- [3] D. Born, "8. cardiopatia congênita," *Arquivos Brasileiros de Cardiologia*, vol. 93, pp. 130–132, 2009.
- [4] A. S. Akinosun, R. Polson, Y. Diaz-Skeete, J. H. De Kock, L. Carragher, S. Leslie, M. Grindle, and T. Gorely, "Digital technology interventions for risk factor modification in patients with cardiovascular disease: systematic review and meta-analysis," *JMIR mHealth and uHealth*, vol. 9, no. 3, p. e21061, 2021.
- [5] M. I. S. Magalhães, M. E. de Moraes Carreiro, I. C. S. de Novaes, D. da Rocha Ferreira, D. B. Lima, Y. M. C. Reyes, R. L. Rossato, E. C. Chiappetta, T. G. Ferreira, W. F. Gazel *et al.*, "Desafios diagnósticos na identificação precoce de doenças cardíacas: Avanços e perspectivas," *Revista Ibero-Americana de Humanidades, Ciências e Educação*, vol. 10, no. 1, pp. 1531–1538, 2024.
- [6] S. Subramani, N. Varshney, M. V. Anand, M. E. M. Soudagar, L. A. Al-keridis, T. K. Upadhyay, N. Alshammari, M. Saeed, K. Subramanian, K. Anbarasu, and K. Rohini, "Cardiovascular diseases prediction by machine learning incorporation with deep learning," *Frontiers in Medicine*, vol. 10, p. 1150933, Apr. 2023. [Online]. Available: <https://www.frontiersin.org/articles/10.3389/fmed.2023.1150933/full>
- [7] S. S. Dahia and C. Szabo, "Implementing Machine Learning to predict the 10-year risk of Cardiovascular Disease," *Qeios*, Sep. 2023. [Online]. Available: <https://www.qeios.com/read/1SVUCI>
- [8] G. Abdulsalam, S. Meshoul, and H. Shaiba, "Explainable heart disease prediction using ensemble-quantum machine learning approach," *Intell. Autom. Soft Comput*, vol. 36, no. 1, pp. 761–779, 2023.
- [9] A. Linardos, K. Kushibar, S. Walsh, P. Gkontra, and K. Lekadir, "Federated learning for multi-center imaging diagnostics: a simulation study in cardiovascular disease," *Scientific Reports*, vol. 12, no. 1, p. 3551, 2022.
- [10] M. Van Smeden, G. Heinze, B. Van Calster, F. W. Asselbergs, P. E. Vardas, N. Bruining, P. De Jaegere, J. H. Moore, S. Denaxas, A. L. Boulesteix *et al.*, "Critical appraisal of artificial intelligence-based prediction models for cardiovascular disease," *European heart journal*, vol. 43, no. 31, pp. 2921–2930, 2022.
- [11] M. B. Malik and A. Goyal, "Cardiac exam," in *StatPearls [Internet]*. StatPearls Publishing, 2023.
- [12] B. A. Hemann, W. F. Bimson, and A. J. Taylor, "The framingham risk score: an appraisal of its benefits and limitations," *American Heart Hospital Journal*, vol. 5, no. 2, pp. 91–96, 2007.
- [13] J. Hippisley-Cox, C. Coupland, Y. Vinogradova, J. Robson, M. May, and P. Brindle, "Derivation and validation of qrisk, a new cardiovascular disease risk score for the united kingdom: prospective open cohort study," *Bmj*, vol. 335, no. 7611, p. 136, 2007.
- [14] I. Talha, N. Elkhoudri, and A. Hilali, "Major Limitations of Cardiovascular Risk Scores," *Cardiovascular Therapeutics*, vol. 2024, no. 1, p. 4133365, Jan. 2024. [Online]. Available: <https://onlinelibrary.wiley.com/doi/10.1155/2024/4133365>
- [15] S. Chakraborty, R. Tomsett, R. Raghavendra, D. Harborne, M. Alzantot, F. Cerutti, M. Srivastava, A. Preece, S. Julier, R. M. Rao *et al.*, "Interpretability of deep learning models: A survey of results," in *2017 IEEE smartworld, ubiquitous intelligence & computing, advanced & trusted computed, scalable computing & communications, cloud & big data computing, Internet of people and smart city innovation (smartworld/SCALCOM/UIC/ATC/CBDcom/IOP/SCI)*. IEEE, 2017, pp. 1–6.
- [16] G. Stiglic, P. Kocbek, N. Fijacko, M. Zitnik, K. Verbert, and L. Cilar, "Interpretability of machine learning-based prediction models in healthcare," *Wiley Interdisciplinary Reviews: Data Mining and Knowledge Discovery*, vol. 10, no. 5, p. e1379, 2020.
- [17] J. Fardouly, R. D. Crosby, and S. Sukunesan, "Potential benefits and limitations of machine learning in the field of eating disorders: current research and future directions," *Journal of Eating Disorders*, vol. 10, no. 1, p. 66, 2022.
- [18] A. P. Hardin, J. M. Hackell, COMMITTEE ON PRACTICE AND AMBULATORY MEDICINE, G. R. Simon, A. D. A. Boudreau, C. N. Baker, G. A. Barden, K. E. Meade, S. B. Moore, and J. Richerson, "Age Limit of Pediatrics," *Pediatrics*, vol. 140, no. 3, p. e20172151, Sep. 2017. [Online]. Available: <https://publications.aap.org/pediatrics/article/140/3/e20172151/383333/Age-Limit-of-Pediatrics>
- [19] J. Morales, "obesidad," *Un enfoque multidisciplinario. Hidalgo, México: Editorial Las Tres Gracias*, vol. 219, 2010. [Online]. Available: https://www.uaeh.edu.mx/investigacion/productos/4823/libro_de_obesidad.pdf
- [20] J. A. Narloch and M. E. Brandstater, "Influence of breathing technique on arterial blood pressure during heavy weight lifting," *Archives of Physical Medicine and Rehabilitation*, vol. 76, no. 5, pp. 457–462, May 1995. [Online]. Available: <https://linkinghub.elsevier.com/retrieve/pii/S0003999395805788>
- [21] L. Chhabra, N. Goel, L. Prajapat, D. H. Spodick, and S. Goyal, "Mouse Heart Rate in a Human: Diagnostic Mystery of an Extreme Tachyarrhythmia," *Indian Pacing and Electrophysiology Journal*, vol. 12, no. 1, pp. 32–35, Jan. 2012. [Online]. Available: <https://linkinghub.elsevier.com/retrieve/pii/S0972629216304636>
- [22] G. F. Berkelmans, S. H. Read, S. Gudbjörnsdottir, S. H. Wild, S. Franzen, Y. Van Der Graaf, B. Eliasson, F. L. Visseren, N. P. Paynter, and J. A. Dorresteijn, "Population median imputation was noninferior to complex approaches for imputing missing values in cardiovascular prediction models in clinical practice," *Journal of Clinical Epidemiology*, vol. 145, pp. 70–80, 2022.
- [23] R. Malarvizhi and A. S. Thanamani, "K-nearest neighbor in missing data imputation," *Int. J. Eng. Res. Dev*, vol. 5, no. 1, pp. 5–7, 2012.
- [24] Z. Zhang, "Multiple imputation with multivariate imputation by chained equation (mice) package," *Annals of translational medicine*, vol. 4, no. 2, 2016.

- [25] E. Poslavskaya and A. Korolev, "Encoding categorical data: Is there yet anything 'hotter' than one-hot encoding?" *arXiv preprint arXiv:2312.16930*, 2023.
- [26] O. Kramer and O. Kramer, "Scikit-learn," *Machine learning for evolution strategies*, pp. 45–53, 2016.
- [27] M. Feurer and F. Hutter, "Hyperparameter optimization," *Automated machine learning: Methods, systems, challenges*, pp. 3–33, 2019.
- [28] M. W. Browne, "Cross-validation methods," *Journal of mathematical psychology*, vol. 44, no. 1, pp. 108–132, 2000.
- [29] G. Guo, H. Wang, D. Bell, Y. Bi, and K. Greer, "Knn model-based approach in classification," in *On The Move to Meaningful Internet Systems 2003: CoopIS, DOA, and ODBASE: OTM Confederated International Conferences, CoopIS, DOA, and ODBASE 2003, Catania, Sicily, Italy, November 3-7, 2003. Proceedings.* Springer, 2003, pp. 986–996.
- [30] G. I. Webb, E. Keogh, and R. Miikkulainen, "Naïve bayes," *Encyclopedia of machine learning*, vol. 15, no. 1, pp. 713–714, 2010.
- [31] M. P. LaValley, "Logistic regression," *Circulation*, vol. 117, no. 18, pp. 2395–2399, 2008.
- [32] W. S. Noble, "What is a support vector machine?" *Nature biotechnology*, vol. 24, no. 12, pp. 1565–1567, 2006.
- [33] M. W. Gardner and S. Dorling, "Artificial neural networks (the multilayer perceptron)—a review of applications in the atmospheric sciences," *Atmospheric environment*, vol. 32, no. 14-15, pp. 2627–2636, 1998.
- [34] G. Castro, A. Medeiros, P. Pires, and T. Almeida, "Ufscar :: Am 2024 :: Projeto final," <https://kaggle.com/competitions/ufscar-am-2024-projeto-final>, 2024, kaggle.